



CRISP - DM

Fases del proceso

1





Why 85% of AI projects fail

Learn from other people's mistakes. Life is too short to make them all yourself.



Nechu BM · Follow

Published in Towards Data Science · 6 min read · Nov 11, 2020



Fases de un proyecto IA & datos

1. Alinear con estrategia
2. Considerar el impacto
3. Definir el alcance real
4. Definir una pregunta SMART
5. Desarrollar un objetivo, metodología y recursos (personas, recursos computacionales, datos).

5

Fases de un proyecto IA & datos

1. Alinear con estrategia
2. Considerar el impacto
3. Definir el alcance real
4. Definir una pregunta SMART
5. Desarrollar un objetivo, metodología y recursos (personas, recursos computacionales, datos).

6




Fases de un proyecto IA & datos

1. Alinear con estrategia
2. Considerar el impacto
3. Definir el alcance real
4. Definir una pregunta SMART
5. Desarrollar un objetivo, metodología y recursos (personas, recursos computacionales, datos).

Fases de un proyecto IA & datos

1. Alinear con estrategia
2. Considerar el impacto
3. Definir el alcance real
4. Definir una pregunta SMART
5. Desarrollar un objetivo, metodología y recursos (personas, recursos computacionales, datos).

9



Fases de un proyecto IA & datos

1. Alinear con estrategia
2. Considerar el impacto
3. Definir el alcance real
4. Definir una pregunta SMART
5. Desarrollar un objetivo, metodología y recursos (personas, recursos computacionales, datos).

11

Fases de un proyecto IA & datos

1. Alinear con estrategia
2. Considerar el impacto
3. Definir el alcance real
4. Definir una pregunta SMART
5. Desarrollar un objetivo, metodología y recursos (personas, recursos computacionales, datos).

12

Niveles de análisis de datos

Descriptivo	Diagnóstico	Predictivo	Prescriptivo
¿Qué pasó?	¿Por qué pasó?	¿Qué sucederá?	¿Qué hay que hacer?
Foto del pasado.	La explicación del pasado.	Dados los resultados pasados, qué sucederá en el futuro.	Usar modelos predictivos para probar estrategias y posibles resultados estimados.
Herramientas: Tablas dinámicas, medidas de tendencia central, histogramas, SQL básico.	Herramientas: Correlaciones, regresiones, business intelligence. BI y SQL avanzados.	Herramientas: Modelos predictivos, machine learning, clasificación, regresión. Python y R.	Herramientas: Clusterización, machine learning, A/B testing, aprendizaje no supervisado.

<https://www.martinsgalloni.com/para-que-sirven-los-datos-breve-introducción-a-los-niveles-de-análisis-y-sus-posibles-usos-en-marketing/>

Fases de un proyecto IA & datos

1. Alinear con estrategia
2. Considerar el impacto
3. Definir el alcance real
4. Definir una pregunta SMART
5. Desarrollar un objetivo, metodología y recursos (personas, recursos computacionales, datos).



Fases de un proyecto IA & datos

1. Alinear con estrategia
2. Considerar el impacto
3. Definir el alcance real
4. Definir una pregunta SMART
5. Desarrollar un objetivo, metodología y recursos (personas, recursos computacionales, datos).

15

Pregunta clave de esta fase


¿Cómo impacto el negocio utilizando IA o Datos?



Los Datos


- Materia prima.
- "Huella dactilar".
- Necesitan tratamiento.
- Activo estratégico.
- Monetizable.
- Granularidad.
- [How businesses use data to create value](#)

(1:38)




19

¿Cómo puede una empresa adquirir un activo estratégico?



20

¿Cómo puede una empresa adquirir un activo estratégico?



21

Fuentes de datos

INTERNAL DATA SOURCES:	EXTERNAL DATA SOURCES:
Corporate ERP modules	Social media
Internal documents	Official statistics
Sensors, controllers	Weather forecasts
In-house call-centers	Publicly available data sets for machine learning
Website logs	

- **Fuentes internas:** departamentos de producción, finanzas, riesgo, servicio al cliente, mercadeo, recursos humanos, etc.
- [Fuentes externas gratis.](#)
- [Fuentes gubernamentales.](#)
- **Proveedores pagos:** Nielsen, Dunnhumby, Facebook, Twitter, etc.
- **Internet de las cosas** (*Internet of Things – IoT*).

.... y muchos más...

<https://datasetsearch.research.google.com>

22



UNSTRUCTURED DATA




STRUCTURED DATA

<https://blog.kensho.com/structured-vs-unstructured-data-what-you-need-to-know-f1e7ce61cd1e>

Entendimiento de los datos

¿Puedo responder la pregunta SMART con los datos que tengo?







¿Qué se busca con el entendimiento de los datos?



- Extracción de rangos, medidas de tendencia central y de dispersión.
- Visualización.
- Limpieza:
 - Analizar valores faltantes y tomar decisiones al respecto.
 - Encontrar anomalías y excepciones.
- Definir transformaciones.
- Escoger las variables que se van a utilizar.
- Crear nuevas variables si se considera que es necesario.

25




26

Visualización de multiples variables del dataset Auto MPG:

- fuel efficiency (in miles per gallon, MPG)
- acceleration (time from 0-60MPH in sec)
- engine displacement (in cubic inches)
- Weight
- horsepower.


Con respecto al número de cilindros (cyan for 3 cylinders, blue for 4, magenta for 5, green for 6, and red for 8).



Conjunto de datos: Auto MPG Data Set.
<http://archive.ics.uci.edu/ml/datasets/Auto+MPG>

Fuente: <https://www.mathworks.com/help/stats/visualizing-multivariate-data.html>

27



Fuente: Hyndsight.


28

Estos conjuntos de datos tiene los mismos parámetros estadísticos (media y desviación estándar) aunque los datos son diferentes!!!

Fuente: Hyndsight.



Same stats different graphs



29



**Todos los
negocios
modernos son
negocios de datos.**




**22 DE MAYO | 11 AM PT
REGÍSTRESE HOY**



Data science

Análisis de **grandes** fuentes de datos combina **estadística**, **inteligencia artificial** e **ingeniería de computación**.


<https://aws.amazon.com/es/what-is/data-science/>



<https://ai.plainenglish.io/data-science-vs-artificial-intelligence-vs-machine-learning-vs-deep-learning-561974615145>

Pregunta clave de esta fase

¿Tengo datos suficientes y de calidad para responder al reto?



Practice time!



- Create
- Home
- Competitions
- Datasets**
- Models
- Code
- Discussions
- Learn
- More

Search

Sign InRegister

Datasets

Explore, analyze, and share quality data. [Learn more](#) about data types, creating, and collaborating.

+ New Dataset

Search datasets

Filters

All datasets

Computer Science

Education

Classification

Computer Vision

NLP

Data Visualization

Pre-Trained Model



GOV.CO | DATOS ABIERTOS

Inicio Descubre Publica Visualiza Participa Herramientas Novedades Usos Activos Calidad

Español Iniciar sesión

957 Resultados Se filtró por Tipos de vista > Gráficos x Borrar todos Ordenar por Más importante

Probabilidad de accidentalidad SE HA CREADO UNA COMUNIDAD


Transporte


DEFINICIÓN DE TRAMOS HOMOGÉNEOS
Sobre un archivo geográfico de la red vial carretera nacional, con las principales vías nacionales de la red primaria y secundaria, que se encuentre particionada en diferentes elementos los cuales no deben superar una longitud máxima de 10 kilómetros, para los elementos con una mayor longitud deben ser separados en partes que contengan longitudes menores a esta longitud.

Esta red debe contener un código único que permita identificar cada tramo vial de forma independiente (COD).

SELECCIÓN DE SINIESTROS VIALES

<https://datos.gov.co/browse?limitTo=charts&page=5>






Niveles de análisis de datos


Descriptivo	Diagnóstico	Predictivo	Prescriptivo
¿Qué pasó?	¿Por qué pasó?	¿Qué sucederá?	¿Qué hay que hacer?
Foto del pasado.	La explicación del pasado.	Dados los resultados pasados, qué sucederá en el futuro.	Usar modelos predictivos para probar estrategias y posibles resultados estimados.
Herramientas: Tablas dinámicas, medidas de tendencia central, histogramas, SQL básico.	Herramientas: Correlaciones, regresiones, business intelligence. BI y SQL avanzados.	Herramientas: Modelos predictivos, machine learning, clasificación, regresión. Python y R.	Herramientas: Clusterización, machine learning, A/B testing, aprendizaje no supervisado.

<https://www.martinsgattori.com/para-que-sirven-los-datos-breve-introduccion-a-los-niveles-de-analisis-y-sus-posibles-usos-en-marketing/>



(AI) is a branch of computer science focused on **creating systems** that display **intelligent behaviour** by **analysing** their environment and taking actions – with some degree of autonomy – to achieve specific goals.

Sheikh, H., Prins, C., Schrijvers, E. (2023)




Aprendizaje automático (ML)

¿Por qué es necesario?



- Tareas complejas difíciles de programar.
- Poder computacional disponible para tratar grandes volúmenes de datos.

Las máquinas deberían aprender por si mismas.



Machine learning es la rama de la IA, cuyo objetivo es desarrollar técnicas para que las computadoras **aprendan**.

Se dice que aprenden cuando su **desempeño** mejora con la **experiencia** y el uso de **datos**. (Sin programación)







<https://quizizz.com/media/resource/gs/quizizz-media/quizzes/6044b379-dbf1-421d-b533-31ad29f49bc2?w=900&h=900>

3. ¿Qué es el aprendizaje automático?

- a) Un campo de la IA que estudia cómo las computadoras pueden aprender de los datos.
- b) Un tipo de hardware que mejora con el tiempo.
- c) Un proceso que no requiere datos para mejorar.
- d) Un algoritmo que solo se usa en robótica.




https://www.cloudskillsboost.google/course_templates/53
6



<https://www.ceupe.com/blog/aprendizaje-supervisado.html>

Aprendizaje supervisado



Anger

Disgust

Fear

Happiness

Sadness

Surprise

Neutral

visage|SDK demo

FACE TRACKING

☒ Feature points

☒ Feature point quality

☐ Face model axis

☐ Wireframe

FACE ANALYSIS

☐ Gender

☒ Emotions

FACE RECOGNITION

☐ Match faces

Start your free trial

Low accuracy, higher performance

TRACK TIME: 16.93 ms

FRAME RATE: 30.65 fps

TRANSLATION: [-0.03,-0.01,0.61]

ROTATION: [-0.22,0.01,-0.04]

STATUS: TRACK_STAT_OK


<https://visage technologies.com/HTML5/latest/Samples/ShowcaseDemo/ShowcaseDemo.html>




<https://quizizz.com/media/resource/gs/quizizz-media/quizzes/6044b379-dbf1-421d-b533-31ad29f49bc2?w=900&h=900>

5. En el aprendizaje supervisado, ¿qué se utiliza para entrenar el modelo?



- a) Datos no etiquetados.
- ☒ b) Datos etiquetados.
- c) Datos generados aleatoriamente.
- d) Datos únicamente de texto




https://www.cloudskillsboost.google/course_templates/53
6



<https://towardsdatascience.com/supervised-vs-unsupervised-learning-in-2-minutes-72dad148f242>





The Great Hack | Official Trailer | Netflix



Netflix
27.2M subscribers

Subscribe

71K



Share



Download




https://www.youtube.com/watch?v=-bLGb_cr1i8

NEGOCIOS

ANÁLISIS | Si EE.UU. prohíbe TikTok, China probará su propia medicina

Por [Laura He](#)

10:22 ET(14:22 GMT) 14 Marzo, 2024



MÁS DE TECNOLOGÍA



SpaceX lanza con éxito Stars potente cohete jamás constr

Al usar este sitio, usted acepta que las cookies se guarden en su dispositivo para mejorar la navegación del sitio, analizar el uso del

[Configuración de cookies](#)




<https://quizizz.com/media/resource/gs/quizizz-media/quizzes/6044b379-dbf1-421d-b533-31ad29f49bc2?w=900&h=900>

11. ¿Qué es el aprendizaje no supervisado?

- a) Un método de aprendizaje donde los datos no están etiquetados.
- b) Un proceso que siempre requiere intervención humana.
- c) Un tipo de aprendizaje que solo se aplica a datos de texto.
- d) Un algoritmo que no puede mejorar con el tiempo.

12. ¿Cuál de los siguientes es un ejemplo de aprendizaje no supervisado?

- *a) Agrupar clientes en segmentos basados en sus comportamientos de compra.
- b) Predecir el precio de una acción en la bolsa.
- c) Clasificar correos electrónicos como spam o no spam.
- d) Detectar fraude en transacciones financieras.



https://www.cloudskillsboost.google/course_templates/536



Unity Machine Learning - Reinforcement Learning Demo



Unity

1.17M subscribers

Subscribe



640



Share



Download



<https://www.youtube.com/watch?v=fiQsmdwEGT8>




<https://quizizz.com/media/resource/gs/quizizz-media/quizzes/6044b379-dbf1-421d-b533-31ad29f49bc2?w=900&h=900>



7. ¿Qué es el aprendizaje por refuerzo?

- a) Un tipo de aprendizaje automático donde un agente aprende a tomar decisiones mediante recompensas y castigos.
- b) Un método para mejorar la precisión de los modelos supervisados por medio de anonimización.
- c) Una técnica para reducir el tamaño de los datos.
- d) Un proceso para etiquetar datos automáticamente basado en datos históricos.

8. En el aprendizaje por refuerzo, ¿qué se entiende por recompensa?


- a) El tiempo que tarda el modelo en entrenar.
- b) Un valor que indica que tan buena es una acción tomada por el agente.
- c) La cantidad de datos utilizados para el entrenamiento.
- d) El tamaño del modelo resultante.








Aplicaciones cotidianas



2010–2020: Large scale supervised learning



© DeepLearning.AI

Andrew Ng




<https://quizizz.com/media/resource/gs/quizizz-media/quizzes/6044b379-dbf1-421d-b533-31ad29f49bc2?w=900&h=900>

4. ¿Cuál de los siguientes es un ejemplo de aprendizaje automático?

- a) Un sistema que recomienda cada vez mejor los productos en una tienda en línea.
- b) Un procesador que incrementa su velocidad automáticamente.
- c) Un sistema operativo que se actualiza cuando lo solicitamos.
- d) Una impresora que imprime con alta calidad.


¿Qué podemos hacer?

Clasificación: predecir la categoría de un ítem. (pago o retiro).



¿Qué podemos hacer?


- **Clasificación:** predecir la categoría de un ítem (pago o retiro).
- **Regresión:** predecir un valor continuo. (Ingresos próximo mes)



81

¿Qué podemos hacer?


- **Clasificación:** predecir la categoría de un ítem.
- **Regresión:** predecir un valor continuo.
- **Detección de excepciones:** encontrar anomalías (Fraudes)



82

¿Qué podemos hacer?

- **Clasificación:** predecir la categoría de un ítem.
- **Regresión:** predecir un valor continuo.
- **Detección de excepciones:** encontrar anomalías.
- **Agrupamiento:** encontrar grupos de elementos similares (productos similares).



83

¿Qué podemos hacer?



- **Clasificación:** predecir la categoría de un ítem.
- **Regresión:** predecir un valor continuo.
- **Detección de excepciones:** encontrar anomalías.
- **Agrupamiento:** encontrar grupos de elementos similares.
- **Asociaciones:** encontrar reglas de coocurrencia.



84

¿Qué podemos hacer?

- **Clasificación:** predecir la categoría de un ítem.
- **Regresión:** predecir un valor continuo.
- **Detección de excepciones:** encontrar anomalías.
- **Agrupamiento:** encontrar grupos de elementos similares.
- **Asociaciones:** encontrar reglas de coocurrencia.
- **Pronóstico:** encontrar secuencias de eventos.



Practice time!

Ejercicio: Tipos de problemas


Clasificación
Regresión
Detección excepciones
Agrupamiento
Asociaciones
Pronóstico

- ¿Cuáles son las personas más susceptibles de convertirse en clientes? **Clasificación**
- ¿Cuántas personas necesito en navidad para atender la carga adicional? **Regresión**
- Tengo dinero para hacer cuatro campañas de mercadeo. ¿Cómo segmentar los clientes? **Agrupamiento**
- Dado que este cliente tiene cuenta de ahorros, tarjeta de crédito y seguro de carro con mi entidad, ¿cuál es el mejor producto para ofrecerle ahora? **Asociación**
- ¿Cuáles son los clientes más parecidos a este cliente? **Agrupamiento**
- ¿Cuánto me va a comprar este cliente el próximo mes? **Regresión**
- ¿A qué máquinas debería hacerles mantenimiento preventivo? **Detección de excepciones**
- ¿Cuánto dinero debería invertir en publicidad en radio, televisión e internet? **Regresión**
- ¿Cuál es el nivel de inventario óptimo para cada producto en cada semana del año? **Pronóstico**

87

Clasificación de clientes.

¿Cómo puedo identificar las mujeres que están embarazadas a partir de sus compras?



88

Prevención del abandono de clientes (*churn*).


¿Cuáles de mis clientes son los más propensos a dejarme por mi competidor?



89

Sistemas de recomendación.

¿Cuáles son las películas más apropiadas para este usuario?




Detección de fraude de tarjeta de crédito.

¿Esta transacción con tarjeta de crédito es legítima o fraudulenta?



91




¿Cómo armar un equipo de beisbol ganador con un presupuesto pequeño?



92

Reconocimiento de correo no deseado (*spam*).

¿Este correo es deseado o no-deseado (*ham* vs. *spam*)?



93

Búsqueda de información.

¿Cuales son los mejores recursos de información dados estos términos de búsqueda?



1998



94

8 Risk Factors of *Diabetes*



Age above
40



Inactive
Lifestyle



High Blood
Pressure



Gestational
Diabetes



Impaired
Glucose
Tolerance



Abnormal
Blood Lipid
Levels





BMI above
23kg/m²




Family
History




Data the Key **driver** for AI strategies





Aprendizaje automático


El aprendizaje automático es la ciencia que permite a un sistema aprender a partir de los datos, en lugar de aprender mediante una programación explícita.



100


Aprendizaje automático

El aprendizaje automático es la ciencia que permite a un sistema aprender a partir de los datos, en lugar de aprender mediante una programación explícita.




Aprendizaje automático

El aprendizaje automático es la ciencia que permite a un sistema aprender a partir de los datos, en lugar de aprender mediante una programación explícita.




Aprendizaje automático

El aprendizaje automático es la ciencia que permite a un sistema aprender a partir de los datos, en lugar de aprender mediante una programación explícita.




103




Assumptions of Linear Regression




1. Linearity
(Linear relationship between Y and each X)



2. Homoscedasticity
(Equal variance)



3. Multivariate Normality
(Normality of error distribution)




4. Independence
(of observations. Includes "no autocorrelation")




5. Lack of Multicollinearity
(Predictors are not correlated with each other)



6. The Outlier Check
(This is not an assumption, but an "extra")



© SuperDataScience



	Business Understanding	Data Understanding	Data Preparation	Modeling	Evaluation	Deployment
Data Scientist	Mid	High	Mid	Top	High	Lower
Data Engineer	Mid	High	Top	Lower	Lower	Mid
Data Analyst	Mid	Top	Mid	Mid	Lower	Lower
ML Engineer	Mid	Lower	Mid	Mid	High	Top
Product Owner	Top	Mid	Lower	Lower	Top	Lower
Project Manager	High	Lower	Lower	Lower	Mid	Mid