

FACULTAD DE INGENIERÍA, DISEÑO Y CIENCIAS APLICADAS
ESCUELA DE TECNOLOGÍA, DISEÑO E INNOVACIÓN.
DEPARTAMENTO DE TECNOLOGÍAS DE INFORMACIÓN Y
COMUNICACIONES (TIC)

Información de la asignatura

Programa	Maestría en ciencia de datos/ Maestría en Inteligencia artificial aplicada
Periodo Académico	
Grupo	
NRC	
Nombre de la asignatura	Fundamentos de Análisis de datos I (Análisis Exploratorio de Datos)
Código de la asignatura	
Intensidad horaria¹	24 horas
Intensidad semanal¹	
Créditos¹	2
Docente(s)	Jose Armando Ordoñez Cordoba

Introducción o presentación general del curso

El análisis exploratorio de datos (Exploratory Data Analysis – EDA) es una de las etapas más importantes del ciclo de vida de un proyecto de analítica, en la cual se abarca el entendimiento, la preparación y la descripción de los datos. De esta manera, el objetivo de esta etapa no solo es determinar si los datos recibidos permiten desarrollar el objetivo de investigación planteado en el proyecto de analítica, sino que también permite tomar decisiones en la formulación de hipótesis y la elección de metodologías y modelos de estimación. En tal sentido, las principales tareas que se llevan a cabo en esta etapa son: entender la estructura general de los datos, detectar anomalías, describir las características de las variables, explorar relaciones entre ellas, formular nuevas hipótesis e identificar tipos de modelos o metodologías para analizar la información. En un proyecto de analítica se plantean objetivos de investigación, pero es el análisis exploratorio de datos el que permite conocer preliminarmente si dichos objetivos pueden ser alcanzados con los datos con que se cuentan.

Formación en competencias**C: Competencia / RA: Resultado de Aprendizaje**

C1. Comunicación Efectiva. Comunicarse adecuadamente usando el mensaje, canales y medios apropiados al contexto y audiencia objetivo..

RA1.1. Desarrollar una estrategia de comunicación escrita ajustada a las características del contexto y de la audiencia objetivo.

¹ La intensidad horaria, intensidad semanal y créditos, deben estar alineados con la “Política de definición de créditos académicos de la Universidad Icesi” – Resolución N°. 80 de Junta Directiva del 22 de septiembre de 2019.

RA1.2. Desarrollar una estrategia de comunicación oral ajustada a las características del contexto y de la audiencia objetivo.

C2. Ética y Responsabilidad Social. Actuar en la práctica profesional teniendo en cuenta la responsabilidad ética y social.

RA2.1. Decidir de manera ética previo al desarrollo de sus acciones, considerando los impactos que estas puedan generar.

C3. Solución de Problemas. Solucionar problemas complejos usando pensamiento sistémico e información relevante.

RA3.1 Examinar problemas complejos aplicando el pensamiento sistémico y plantear soluciones basadas en conocimiento e información relevante.

C5. Competencia profesional: Aplicar herramientas y técnicas para explorar, extraer, transformar, almacenar y procesar datos estructurados y no estructurados, de diferentes fuentes, formatos y tamaños .

RA.5.1: Aplicar herramientas y técnicas de ingesta de datos para extraer y transformar datos de diversas fuentes y formatos

R.5.2: Implementar estrategias de almacenamiento y procesamiento de datos a gran escala para manejar volúmenes significativos de información

Tabla 1: competencias y Nivel de formación

Competencia	Nivel
1. Comunicación efectiva.	Introduce
2. Ética y responsabilidad social	Introduce
3. Solución de problemas	Introduce
4. Competencia profesional	Introduce

Objetivo general–meta de aprendizaje

Al finalizar el curso, el estudiante estará en capacidad de realizar el análisis exploratorio en un proyecto de analítica de datos, utilizando estadísticas descriptivas y técnicas de visualización de datos.

Objetivos terminales–resultados de aprendizajes de la asignatura

A partir de los elementos propios de un análisis exploratorio de datos en el marco de un proyecto de analítica, el estudiante estará en capacidad de:

1. Comprender la estructura general de los datos.
2. Preparar los datos de manera que cumplan con las condiciones necesarias para ser utilizados dentro del proyecto de analítica de datos.

3. Describir las características de los datos, utilizando estadísticas descriptivas y técnicas de visualización.

Objetivo terminal–resultado de aprendizaje del curso o asignatura	Competencia en formación	Resultado de aprendizaje de la competencia de egreso al que se contribuye
OT1	C2, C3, C5	RA2.1, RA3.1, RA5.1, RA5.2
OT2	C3, C5	RA3.1, RA5.1, RA5.2
OT3	C1, C2, C5	RA1.1, RA1.2, RA2.1, RA5.1, RA5.2

Unidades de aprendizaje

Unidad 1. Entendimiento general de los datos

Al finalizar esta unidad el estudiante estará en la capacidad de:

- Identificar los conceptos relacionados con el análisis exploratorio de datos
- Reconocer la importancia de la calidad de los datos
- Interpretar un requerimiento técnico y expresarlo como una pregunta SMART.
- Realizar la carga y análisis de la forma y estructura de un dataset con Python

Temas:

- El análisis exploratorio de datos en el flujo de ciencia de datos
- SMART Questions
- Carga de datos
- Big picture de los datos (tipos de las columnas, estadísticas generales)

Unidad 2. Entender la forma de los datos

Al finalizar esta unidad el estudiante estará en la capacidad de:

- Realizar el análisis y preparación univariado de una columna de un dataset
- Realizar el análisis y preparación bivariado y multivariado de un dataset

Temas:

- Tipos de datos (Categoricos y numéricos)
- Análisis (distribución) univariado y preparación de los datos (Datos erróneos y manejo de outliers)
- Análisis multivariado y preparación de los datos (Datos erróneos y manejo de outliers)

Unidad 3. Preparación de los datos

Al finalizar esta unidad el estudiante estará en capacidad de:

- Realizar la preparación de un dataset
- Utilizar pipelines y custom transformers para la preparación de datos
- Comunicar los resultados del análisis exploratorio de datos

Temas:

- ¿Por qué preparar los datos?
- Escalar y normalizar
- One hot encoding - label encoding
- Feature selection
- Feature engineering"
- Pipelines en Python
- Custom Transformers"

Metodologías de aprendizajes

El curso está planteado para dedicar tres sesiones para cada una de las unidades anteriormente expuestas. De esta manera, cada unidad estará compuesta por una presentación magistral, un ejercicio de aplicación, un taller en casa, un taller en clase y una entrega parcial del proyecto. El Software que se utilizará durante todo el curso es R. Los estudiantes deben participar activamente en las actividades y discusiones propuestas.

Evaluación de aprendizajes

La evaluación del curso comprende actividades grupales e individuales.

Mecanismo o actividad evaluativa	Porcentaje de la nota final	Relación con objetivo terminales – resultado de aprendizaje del curso	Relación con el resultado de aprendizaje de la competencia de egreso
Talleres individuales	40%	OT2	RA2.1, RA5.1, RA5.2 RA3.1
Presentación del proyecto de curso	60%	OT1 OT4	RA1.1, RA1.2, RA2.1, RA5.1, RA5.2

Medios Educativos.

Textos guía:

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). Statistical learning. In An introduction to statistical learning (pp. 15-57). Springer, New York, NY.

Mukhiya, S. K., & Ahmed, U. (2020). Hands-On Exploratory Data Analysis with Python: Perform EDA techniques to understand, summarize, and investigate your data. Packt Publishing Ltd.

Mendenhall, W., Beaver, R. J., Beaver, B. M., & Velázquez Arellano, J. A. (2015). Introducción a la probabilidad y estadística (13a. ed. --.). México, D.F.: Cengage Learning

Recursos recomendados:

Google Data analytics certificate: <https://www.coursera.org/lecture/foundations-data/welcome-to-the-google-data-analytics-certificate-aA1Wv>

Microsoft Azure Data Fundamentals: <https://learn.microsoft.com/en-us/certifications/exams/dp-900>