


Limpieza de datos


Agenda

1. Comprender los pasos del proceso de limpieza.
2. Entender las principales fuentes de problemas en las bases de datos, sus implicaciones y la forma de solucionarlos.
3. Usar Python para limpiar un conjunto de datos

Ciclo de vida de la analítica



Proceso de limpieza



Principales fuentes de problemas

Formato de las
variables no coincide
con el tipo de
variable

Observaciones
duplicadas
(coincidencia exacta)

Valores perdidos

Errores de digitación

Principales fuentes de problemas

Valores
inconsistentes

Valores fuera del
rango o inválidos

Valores sin
referencia en el
diccionario de
variables



Pasos básicos

1. Cargar la base de datos.
2. Identificar cuántas columnas y filas tiene la base de datos.

¿Por qué es importante esta verificación?

Dimensiones de la base de datos

		Rows				
Columns						

NO CORRESPONDENCIA ENTRE EL FORMATO DE LA VARIABLE Y SU TIPO

No correspondencia entre el formato de la variable y su tipo

¿Por qué este paso es importante?

- Facilitar el proceso de hacer gráficos.
- Implementar modelos e interpretar los resultados.

OBSERVACIONES DUPLICADAS




Observaciones duplicadas

¿Por qué este paso es importante?

- Para entender mejor la base de datos
- Evitar la doble contabilización

¿Hay observaciones duplicadas en la base de datos de bancos?



VALORES PERDIDOS

Valores perdidos



“ ”

99



NA


1. Identifique donde se encuentran los valores perdidos y si es necesario recodifíquelos correctamente.

Tip: Maneje el mismo código para indicar que falta un valor en un campo de datos.

2. Intente entender la naturaleza de los datos perdidos.

3. Determine cuál es el mejor método para tratarlos.

Entender el porqué hay valores perdidos



Tratamiento a los valores perdidos

2. Eliminar observaciones con valores perdidos

Fuente: https://liberalarts.utexas.edu/prc/_files/cs/Missing-Data.pdf

Gender	8 th grade math test score	12 th grade math score
F	45	.
M	.	99
F	55	86
F	85	88
F	80	75
.	81	82
F	75	80
M	95	.
M	86	90
F	70	75
F	85	.

```
bd_sinmv<- bd[complete.cases(bd)]
```

Gender	8 th grade math test score	12 th grade math score
F	45	.
M	.	99
F	55	86
F	85	88
F	80	75
.	81	82
F	75	80
M	95	.
M	86	90
F	70	75
F	85	.

```
bd_sinmath8<- bd[!is.na(bd$math8),]
```

Tratamiento a los valores perdidos

3. Imputación de datos: sustituir valores perdidos en un campo por otros empleando:

- Media
- Mediana
- Moda
- Predicción de esos valores faltantes empleado modelos estadísticos

ERRORES DE DIGITACIÓN

Errores de digitación

Convenciones de denominación

- NYC vs New York

Representaciones diferentes

- Si, si, Sí

Espacios vacíos

- “Mujer” vs “ Mujer ”

Para identificarlos empleé la función **table**.



Errores de digitación

Encuentre los errores de digitación en la base de datos de bancos y corríjalos.

Pista: Las variables con errores de digitación son marital, housing, y default

¿Para qué corregir los errores de digitación?

VALORES INCONSISTENTES

Valores inconsistentes

Estos valores se hallan analizando la consistencia de las respuestas entre variables que se encuentran relacionadas.

Edad	Fecha de nacimiento	Edad calculada
27	1990/01/17	27
21	1995/05/14	21
60	11/11/1956	60
47	7/04/1940	77
37	12/08/1980	37

- La detección de estos valores inconsistentes dependerán del conocimiento y la lógica del analista.
- Función de R: table



Valores inconsistentes

- ¿Qué relaciones entre variables podríamos revisar?

Por ejemplo, que las personas que respondieron que no tenían hijos, hayan respondido 0 en el número de hijos.

Valores inconsistentes

Solución

Convertir los valores inconsistentes en valores perdidos.

Sin embargo, si tiene acceso a la fuente de datos original (encuesta), puede revisar las respuestas y corregir si es necesario.

**VALORES FUERA DEL RANGO O INVÁLIDOS,
O SIN REFERENCIA EN EL DICCIONARIO DE
VARIABLES**

Valores fuera del rango o inválidos

Nombre	Altura (m)	Nombre	Ingreso mensual
Juan	1.6	María	5.000.000
Camilo	1.85	Diego	5.500.000
Esteban	1.72	Alba	7.000.000
Santiago	1.76	Iván	2.500.000
María	1.65	Juan	Mucho
Paola	-1.58	Andrea	3.000.000

Valores sin referencia en el diccionario de variables

Nombre	Estado Civil	Código Estado Civil	
Paola	1	1	Soltero
Esteban	4	2	Casado
Cesar	5	3	Separado o divorciado
Carlos	8	4	Unión libre
María	3	5	Viudo
Mayra	2		
Roberto	1		

¿Cómo detectarlos?

table
Tabla de frecuencias



Diccionario
de variables

CREACIÓN DE NUEVAS VARIABLES



Creación de nuevas variables

¿Cuántas personas son propietarias de su casa y están en mora?

Responda las otras preguntas:

¿Cuántas personas tienen menos de 25 años y son estudiantes?

¿Cuántas personas tienen más de 60 años y están jubilados?