



Análisis de Datos I – 252

[Inicio](#)[Presentación](#)[Unidad 1](#)[Unidad 2](#)[Unidad 3](#)

Unidad 3: Preparación de los Datos

Unidad 3: Preparación de los Datos

En esta unidad, nos enfocaremos en la preparación de los datos, un paso crucial en el análisis y modelado de datos. Al finalizar esta unidad, el estudiante será capaz de preparar adecuadamente los datos para el análisis y la creación de modelos, utilizando diversas técnicas y herramientas.

Temas de la Unidad:

- ¿Por qué preparar los datos?
- Escalar y normalizar
- One hot encoding – label encoding
- Feature selection
- Feature engineering
- Pipelines en Python
- Custom Transformers
- Sustentación de proyectos finales

Presentaciones Unidad 3:

En esta sección encontrarás una serie de presentaciones diseñadas para complementar y profundizar en los temas cubiertos durante la Unidad 3: Preparación de los Datos. Estas presentaciones proporcionan una visión detallada de las técnicas y herramientas necesarias para preparar adecuadamente los datos antes de realizar análisis y modelado.



Recurso

PPT Feature Engineering

Recurso

Multivariate graphical Analysis

Antes de la clase 4:

Para prepararte adecuadamente para la próxima clase, te invitamos a revisar el siguiente ejemplo de un proyecto de ciencia de datos. Este recurso te proporcionará una visión práctica de la aplicación de técnicas de preparación de datos en un contexto real.

Revisión de un Proyecto de Ciencia de Datos:

1. Te recomendamos explorar el siguiente notebook que aborda la carga de datos en formato Parquet, un formato de almacenamiento de datos eficiente y ampliamente utilizado.

https://github.com/armandoordonez/eda_couse/blob/main/2.2.1-carga-dataset-parquet.ipynb

Durante la clase 4:

Durante la cuarta clase, nos enfocaremos en varios aspectos cruciales de la preparación de datos, incluyendo técnicas de codificación y normalización.

Agenda de la sesión:

1. Seguimiento General a los Proyectos: Continuaremos con la revisión del progreso de los proyectos seleccionados por los estudiantes. Este seguimiento permitirá ofrecer retroalimentación constructiva y asegurar que los estudiantes están aplicando

correctamente los conceptos aprendidos.

2. Preparación de Datos, One Hot Encoding vs Label Encoding, Normalización: Se llevará a cabo una charla magistral que cubrirá en detalle la preparación de datos, comparando las técnicas de One Hot Encoding y Label Encoding, y discutiendo la importancia de la normalización. Se explorarán diferentes métodos y enfoques para tratar estos desafíos comunes en el análisis de datos.

3. Laboratorios:

- laboratorio: Impacto de One Hot Encoding y Label Encoding: Utilizando el notebook disponible en [GitHub](#), realizarás este taller que se enfoca en analizar el impacto de One Hot Encoding y Label Encoding en los datos. Asegúrate de subir el resultado a tu repositorio de GitHub.
- laboratorio: Estandarización y Normalización: Resolverás los ejercicios prácticos proporcionados en [este notebook](#), que aborda las técnicas de estandarización y normalización. Subirás tus soluciones al repositorio de GitHub para su revisión.
- laboratorio: Label Encoding: Completarás el taller utilizando [este notebook](#), enfocándote en la implementación de Label Encoding. Asegúrate de subir el resultado a tu repositorio de GitHub.
- laboratorio: Predicción de Préstamos (Loan Prediction): Este taller, disponible en [GitHub](#), te llevará a través de un caso práctico de predicción de préstamos, aplicando técnicas de preparación de datos y modelado. Subirás tus soluciones al repositorio de GitHub.

laboratorio Clase 4:



URL

[laboratorio- Impacto de One Hot Encoding y Label Encoding](#)





URL

laboratorio – Estandarización y Normalización



URL

laboratorio – Label Encoding



URL

laboratorio – Predicción de Préstamos (Loan Prediction)



Carpeta

Taller Analisis datos bancarios

Después de la clase 4:

Para consolidar los conocimientos y habilidades adquiridas durante la clase, te invitamos a realizar las siguientes actividades:

1. Realiza la preparación completa de los datos de tu dataset seleccionado para el proyecto final. Asegúrate de aplicar las técnicas de escalado, normalización, codificación (One Hot Encoding y Label Encoding), y cualquier otra transformación necesaria para optimizar tus datos para el análisis y modelado.
2. Actualiza tu repositorio de GitHub con todos los scripts, notebooks y reportes generados durante la preparación de los datos. Mantén tu repositorio organizado y bien documentado, lo cual es esencial para facilitar la revisión y colaboración.



Tarea

Taller 4. Comparte la preparación de los datos

Antes de la clase 5:

Para prepararte adecuadamente para la próxima clase, te invitamos a revisar el siguiente material práctico sobre selección de variables. Este recurso te ayudará a entender y aplicar técnicas de selección de características en tus datos.

Explora y completa el siguiente notebook, que contiene ejercicios prácticos sobre técnicas de selección de variables. Este notebook te proporcionará una comprensión detallada de cómo identificar y seleccionar las características más relevantes de tu conjunto de datos.

Completa los ejercicios y asegúrate de entender los conceptos y métodos presentados, ya que serán fundamentales para las actividades prácticas y discusiones durante la próxima clase.

https://github.com/armandoordonez/eda_couse/blob/main/Practica_Selecci%C3%B3n_de_variables.ipynb

Durante la clase 5:

Durante la quinta clase, nos centraremos en varios temas avanzados relacionados con la preparación de datos y la construcción de pipelines en el contexto de proyectos de ciencia de datos.

Agenda de la sesión:

1. Seguimiento General a los Proyectos: Continuaremos con la revisión y seguimiento de los proyectos individuales. Esto permitirá evaluar el progreso, identificar posibles desafíos y proporcionar orientación adicional según sea necesario.

2. Data Leakage, Pipelines, Custom Transformers, Feature Selection: Se llevará a cabo una charla magistral que abordará temas clave como el data leakage (fuga de datos), la construcción de pipelines automatizados para el procesamiento de datos, la creación de transformadores personalizados y técnicas avanzadas de selección de características.

CARACTERÍSTICAS.

3. Laboratorios:

- **laboratorio: Construcción de Pipelines – Parte 1:** Utiliza el notebook disponible en [GitHub](#) para completar este taller sobre la construcción de pipelines en Python. Asegúrate de subir tus soluciones al repositorio de GitHub.
- **laboratorio: Construcción de Pipelines – Parte 2:** Resuelve los ejercicios prácticos proporcionados en [este notebook](#), que se centra en la construcción avanzada de pipelines. Sube tus resultados al repositorio de GitHub para su revisión.
- **laboratorio: Implementación de Pipeline para Regresión Lineal:** Aplica tus conocimientos en la implementación de pipelines para regresión lineal con el notebook disponible en [GitHub](#). Asegúrate de completar el taller y subir tus soluciones al repositorio de GitHub.
- **laboratorio: Experimentación con Pipelines:** Realiza el taller práctico sobre experimentación con pipelines utilizando [este notebook](#). Completa los ejercicios y sube tus resultados al repositorio de GitHub.
- **laboratorio: Data Leakage:** Utiliza el notebook disponible en [GitHub](#) para explorar y comprender el concepto de data leakage. Completa los ejercicios y asegúrate de subir tus soluciones al repositorio de GitHub.

4. Demostración EDA en la nube: Se realizará una demostración práctica de cómo realizar un [Análisis Exploratorio de Datos](#) (EDA) utilizando herramientas en la nube.

laboratorios Clase 5:

URL

Laboratorio: Construcción de Pipelines – Parte 1

URL

Laboratorio: Construcción de Pipelines – Parte 2

 URL

Laboratorio: Implementación de Pipeline para Regresión Lineal

 URL

Laboratorio: Data Leakage



Carpeta

Taller Salud



Recurso

Solucion al taller de salud

Después de la Clase 5:

1. Preparación de los Datos de tu Dataset: Implementa la preparación completa de los datos de tu dataset seleccionado, aplicando las técnicas discutidas durante la clase, como pipelines, transformadores personalizados y selección de características.

2. Actualizar tu Repositorio de GitHub: Asegúrate de subir y documentar todos los scripts, notebooks y archivos relacionados con la preparación de datos en tu repositorio de GitHub. Mantén una estructura organizada y proporciona comentarios claros sobre cada archivo.

3. Creación de un Video sobre la Preparación de tus Datos: Como parte de la entrega, crea un video breve (aproximadamente 5-10 minutos) donde expliques y demuestres la preparación de tus datos. Puedes utilizar herramientas como Screencast-O-Matic, OBS Studio o cualquier otra herramienta de grabación de pantalla que prefieras. En el video, asegúrate de cubrir los siguientes puntos:

- Problema a resolver y pregunta SMART.
- Hallazgos más importantes en los datos

- hallazgos más importantes en los datos
- Breve discusión sobre los desafíos técnicos encontrados y cómo los superaste.

Antes de la clase 6:

Para prepararte adecuadamente para la próxima clase, te recomendamos revisar el siguiente artículo sobre cómo comunicar los resultados en ciencia de datos. La habilidad para comunicar de manera efectiva los hallazgos y resultados es fundamental en cualquier proyecto de ciencia de datos.

Guía para Comunicar Resultados en Ciencia de Datos:

Lee el artículo disponible en Medium que proporciona una guía completa sobre cómo los científicos de datos pueden comunicar sus resultados de manera efectiva. Este recurso te ofrecerá estrategias y mejores prácticas para presentar y explicar tus hallazgos de manera clara y persuasiva.

<https://medium.com/comet-ml/a-data-scientists-guide-to-communicating-results-c79a5ef3e9f1>

Durante la clase 6:

Durante la sexta clase, exploraremos aspectos prácticos y aplicados de la ciencia de datos, incluyendo la participación de un invitado de la industria y la presentación de los avances en tus proyectos.

Proyección de Videos de Avances en Proyectos.

Durante esta sesión, se proyectarán y discutirán los videos preparados por los estudiantes, donde cada uno presentará los avances en sus proyectos finales. Cada presentación tendrá una duración de aproximadamente 5 minutos, seguida de una sesión de preguntas y retroalimentación de 5 minutos. El enlace a los videos se encuentra en:

<https://docs.google.com/spreadsheets/d/1t0KillfMojhXMWCMutXA8GfBUxXQ-zXAKiGuqsVCjwk/edit?usp=sharing>

Después de la clase 6:

Después de recibir la retroalimentación durante la clase y la sesión de preguntas, es crucial realizar ajustes basados en las sugerencias recibidas para mejorar la calidad y precisión de tu proyecto final.

1. Realizar Ajustes Basados en las Sugerencias de la Retroalimentación:

- Revisa las sugerencias y comentarios recibidos durante la sesión de preguntas y realimentación.
- Implementa los ajustes necesarios en tu proyecto final, enfocándote en áreas específicas como metodología, análisis de resultados, visualización de datos y cualquier otro aspecto señalado para mejorar.

2. Actualizar tu Repositorio de GitHub:

- Asegúrate de reflejar todos los cambios y mejoras realizados en tu proyecto final en el repositorio de GitHub.
- Mantén una estructura organizada y clara en tu repositorio, incluyendo comentarios y descripciones adecuadas para cada archivo y carpeta.



Tarea

Proyecto Final: Realiza el análisis completo de tu dataset

Material de Referencia Adicional:

1. Microsoft Learn – Data Wrangler

- Aprende más sobre Data Wrangler a través de los recursos disponibles en Microsoft Learn. Este recurso te proporcionará conocimientos sobre cómo limpiar y preparar datos de manera efectiva para su análisis y modelado.

4. Limpieza y Análisis EDA del Dataset de Crímenes de Cincinnati

- Explora el notebook [Cincinnati Crime Dataset Cleaning & EDA](#), que ofrece un caso práctico detallado sobre cómo realizar la limpieza y análisis exploratorio de un

dataset específico.

5. Artículo sobre el Despliegue de Modelos de Aprendizaje Automático

- Lee el artículo [Deployment of Machine Learning Models](#) para obtener información adicional sobre cómo implementar y desplegar modelos de aprendizaje automático en entornos de producción.